

Explicação Do Projeto

- Breve explicação sobre as Etapas, Pastas e Códigos

Tratamentos de Erros:	1
1 - Erro de deslocamento de dados	1
2 - Erro na linha final.....	1
GRÁFICO INTERATIVO	2
Case 1.....	2
Case 2.....	2
Pastas:.....	3
Códigos:.....	3
Uso de IA.....	5

Tratamentos de Erros:

1 - Erro de deslocamento de dados

Houve um problema com o acesso aos dados das tabelas. Basicamente, os valores estavam deslocados para a direita, o que fazia com que o dado de uma coluna aparecesse na coluna seguinte (da Feature posterior).

Uma ideia inicial para resolver isso seria mudar o acesso usando o índice (iloc). Mas, pensando na escalabilidade, percebi que se o CSV fosse corrigido no futuro, essa solução poderia parar de funcionar. Então, decidi ir a fundo e encontrar a causa real do problema.

Fui investigar como os dados brutos do CSV estavam escritos e encontrei algumas coisas. Na linha 1, por exemplo, tinha dois delimitadores (;) no final. Isso não causaria o deslocamento, só geraria um valor nulo, o que não era o caso principal.

O problema de verdade estava na linha 0, onde ficam os nomes das colunas (as features). O último dado dessa linha não tinha um delimitador no final. Ou seja, ele só terminava com o delimitador da feature seguinte, que era encontrado em outro processo. Por causa disso, todos os dados eram jogados para uma posição anterior à que deveriam estar.

De novo, pensando em escalabilidade, eu poderia ter editado o CSV na mão. Mas preferi criar um código que verifica se o delimitador existe no final de cada linha. Se existir, nada acontece. Se não existir, o código adiciona o delimitador. Evitando que os dados se desloquem entre as linhas do banco todo. Caso houvesse outro problema do tipo, seriam apenas sobre os dados da coluna específica

2 - Erro na linha final

Outro ponto foi que o banco de dados tinha três linhas extras no final. Elas não eram sobre algum dado nem valores nulos, mas sim metadados, com informações sobre a biblioteca usada, URL e data.

Resolvi isso de um jeito simples: fiz uma busca por linhas que não tinham delimitador. As linhas sem delimitador eram esses metadados, então elas foram removidas do banco de dados final. Assim, garanto que só o que é dado de verdade e útil para análise fique no meu banco.

GRÁFICO INTERATIVO

Optei por criar um Gráfico Interativo do qual permitisse uma grande liberdade personalizável e explorativa dos dados presentes

Criei áreas para mostrar gráficos de Features que achei interessante e relevante para uma análise desse estilo, permitindo opções de escolha por visualização de: Proporção (%) ou Valores quantitativos

Também optei por um sistema de Filtros Dinâmicos, os quais afetam todas as informações presentes nos Dashboards

Inclusive com um sistema de intervalo de datas

Permitindo assim uma possibilidade forte para busca de vários tipos de dados, com focos específicos

Também temos a tabela completa dos dados qualitativos do CSV, onde é possível escolher as Features desejáveis, permitindo fazer uma análise rápida e versátil diante qualquer dado a consultar

Case 1

Apresentado no pdf: PIPE 2026

Na pasta: Apresentação Dash Pipe 2026 / Apresentação Principal

Com área de cabeçalho para facilitar a entrega das requisições pedidas

E área do cabeçalho para todas as demais análises feitas

Case 2

Apresentado no pdf: SQL PIPE 2026

Na pasta: Apresentação Dash Pipe 2026 / Apresentação Principal

Com cabeçalho para facilitar a entrega das requisições pedidas

E uma análise extra para a requisição das 3 áreas de conhecimento, devido a questão de instituições possuírem dados totalmente nulos

/Pastas:

- Pasta: Apresentação Dash Pipe 2026

Subpastas:

- Apresentação Principal: Reservada para os pdfs da apresentação dos dados dos cases e dados explorados
- Documentos: todos os arquivos gerados e usados nas apresentações

- Pasta: Data_csv

Possui o Arquivo .csv original da biblioteca FAPESP, antes do tratamento

- Pasta Export_csv

Possui as subpastas:

- **Database:** Contém o arquivo Database da biblioteca FAPESP, já devidamente tratado e pronto para uso nas análises.

- **PIPE e PIPE_Ribeirão_Preto:** Dados categorizados do PIPE e PIPE filtrado por Ribeirão Preto, com pastas para separar as variáveis criadas e exportadas como .csv para os dados quantitativos e qualitativos
- **Insert:** Arquivos .sql para inserir os dados e tabelas no programa do SQL a ser usado
- **Pasta Scr**
Códigos Python: Explicados na área Códigos

Códigos:

Pasta Scr

- **chart_interative:** código do gráfico interativo
- **Charts:** funções de todos os gráficos gerados
- **Def:** Função responsável por separar nomes dos pesquisadores, garantindo que dados com mais de um nome separado por virgula fossem calculados corretamente
- **Insert:** responsável por gerar os arquivos com SQL com os dados organizados
- **Insert_empresas:** gera arquivo sql optativo (meio optativo que usei para uma entrega extra diante as propostas do cases e a totalidade de dados nulos)
- **Main:** Responsável por tratar erros, dados nulos, separar as features, e pela minha feature adicionada: Títulos (essa feature é responsável por entregar títulos em português sempre que possível, garantindo que caso um título seja nulo, mostre o título em inglês como alternativa

- **Path:** construir o caminho para o csv de forma que o diretório não interfira em problemas para tratar o arquivo
- **Search:** Puramente investigativo, onde realizei os prints para garantir a segurança dos dados, e para analisar a quantidade de dados nulos presentes nas features, separados por totalmente nulos, muitos nulos, e poucos nulos
- **Variables_counts e Variables_counts_Ribeirao_preto:**
Responsável pela criação de minhas variáveis quantitativas
- **Variables_Values e Variables_Values_Ribeirao_Preto:**
Responsável pela criação de minhas variáveis qualitativas

Uso de IA

Foram usadas com o intuito de otimizar processos de análise, me permitindo explorar e gerar um maior volume de informações

A IA foi fundamental para agilizar tarefas que, embora essenciais, seguem um padrão de código bem definido. Operações como group by, sum, nunique, gráficos, as verificações de dados com prints... Processos do qual consomem muito tempo quando feitas manualmente. Sistemas de código para essas análises são algo bastante padronizado, variando apenas nas features, variáveis criadas e nas combinações para as especificações desejadas, a IA permitiu automatizar esses passos.

Essa automação liberou meu tempo para uma análise mais aprofundada. Pude usar os prints para confirmar minhas investigações e criar variáveis com dados confiáveis, que foram cruciais para a análise final e para as entregas dos CSVs no Excel. Além disso, essas variáveis foram a base para a criação dos gráficos, que ajudaram a visualizar os resultados.

